

System Design



A diagram consisting of a dashed rectangular box. The top-left corner of the box is connected to the text 'System Design' by a dashed line. The bottom-right corner of the box is connected to the text 'Load Balancers e Proxies Reversos' by a dashed line. A solid vertical line with an upward-pointing arrow is positioned to the right of the box, extending from the level of the bottom text to the level of the top text. A dashed curved arrow starts from the top-right corner of the box and points towards the top of the solid vertical line.

**Load Balancers e
Proxies Reversos**

\$ whoami

Matheus Fidelis

Engenheiro de \$RANDOM

@fidelissauro



<https://fidelissauro.dev>

<https://linktr.ee/fidelissauro>



OBJETIVOS

- ✔ Load Balancers
- ✔ Proxy Reverso
- ✔ Diferenças
- ✔ Papel na escalabilidade e resiliência
- ✔ Algoritmos de distribuição de carga
- ✔ Tecnologias e Implementações modernas



1. Load Balancers

Balanceadores de
Carga de Trabalho

Que problema os LB's Resolvem?

- Unico Servidor
- Sobrecarga de um único host
- Gaps de Performance
- Sem distribuição de Requisições
- Ponto único de falha
- Fila de Supermercado






Load Balancers

- Pattern de Networking
- Gestão de Tráfego de Rede
- Otimização de Recursos
- Alta Disponibilidade de Serviço
- Ponto Único de acesso para vários hosts
- Healthchecks de Segurança
- Evita que hosts individualmente se torne um ponto único de falha



Load Balancers




Load Balancers

Escalabilidade Horizontal


- Load Balancer distribui requisições entre múltiplos servidores
- Suporte a crescimento dinâmico (auto scaling)
- Base para arquiteturas elásticas e tolerantes a falhas
- Permite adição e remoção de hosts dinamicamente sem downtime*
- Warm-up, Drain e etc.



Warm Up





Drain



Load Balancers e Healthcheck

- Health checks monitoram a saúde dos hosts
- Check periódico de saúde
- Podem ser configurados em nível L4 (TCP/UDP) ou L7 (HTTP/HTTPS)
- Requisições são direcionadas apenas a servidores saudáveis
- Evitam degradação da experiência do usuário



1. Proxies Reversos

Reverse Proxy

Proxy Reverso

- Intermediário de um único backend
- Atua de 1:1 garantindo a saúde
- Rate Limit
- Circuit Breaker
- Healcheck e Heart Beat
- Limitações de capacity






1. Load Balancer vs Proxy Reverso


Comparativo

Load Balancers vs Proxy Reverso


- Proxy Reverso: intermediário simples (1:1)
- Load Balancer: escalabilidade e alta disponibilidade (múltiplos hosts no pool)
- Ambos podem coexistir
- Ambos são patterns
- Ambos são construídos com as mesmas tecnologias
- Ex: Envoy Proxy

Load Balancers e Proxy Reverso





1. Algoritmos de Balanceamento



Principais
Tradeoffs


Algoritmos de Balanceamento

- Round Robin: simples, justo, mas ingênuo
- Least Request: Quantidade de Requests
- Least Connection: Quantidade de Conexões
- LOR: inteligência baseada em carga
- IP Hash / Maglev: consistência e persistência de sessão
- Random: simplicidade máxima

Round Robin


- Algoritmo de escalonamento de CPU
- Baseado em Tempo (Quantum)
- Distribuição de carga cíclica
- Evita Starvation (Inanição)
- Evita Sobrecarga Desproporcional
- Diferencial de Simplicidade
- Facilita a Escalabilidade Horizontal
- Adição e Remoção de Hosts

Round Robin




Round Robin - Limitações

- Distribui Carga Iguamente
 - Exigir mais recursos do que outros
 - Não leva o nível de processamento
 - Capacidade não uniforme
 - Consultas vs Relatórios
-
- Spikes
 - Carga Repentina dentro o intervalo de tempo
 - Sobrecarga em um, ou poucos hosts




Least Request

- Envia para o host com menos requisições
- Frequência com que as requisições são atendidas
- Contador associado a cada host ativo
- Incrementa individualmente à medida que as requisições são distribuídas
- Prioriza aquele com o menor contador dentre as opções disponíveis
- Requisições Uniformes e Curtas



Least Request - Limitações


- Desbalanceamento
- Ambientes com requisições muito diversificadas e de durações variadas
- Não considera a saturação dos hosts
- Insuficiente para representar a real distribuição de carga
- Gestão do Contador em Escalabilidade Horizontal - Negação de Serviço (DoS)



Least Connection

- Implementação Sofisticada
- Sistemas Modernas
- Envia para o host com menos conexões ativas
- servidor com o menor número de conexões ativas no momento
- Uma sessão ou interação em andamento entre cliente e servidor
- Conexões Keep Alive, Web Sockets, gRPC

Least Connection



Least Connection - Limitações

- Se concentra no número de conexões ativas, sem avaliar a carga de cada uma delas
- Sobrecarga de servidores que lidam com conexões mais exigentes
- gerenciar essas conexões pode consumir recursos significativos do balanceador
- Keep alives muito longos podem gerar carga falso-positiva


Least Outstanding Requests (LOR)



- Saturação de Hosts
- Evolução do Least Connection
- Problema do "Ativo mas não trabalhando"
- Conexões ativas vs Conexões em uso
- Quantas requisições estão sendo processadas
- Prioridade por hosts com menos requisições
- Balanceamento de Carga de Trabalho

- Ideal para Sistemas Heterogeneos

Least Outstanding Requests (LOR)



LOR - Limitações




- Exige Monitoramento Ativo
- Monitoramento Detalhado
- Complexidade de Implementação
- Desempenho do balanceador
- Variação Repentina de Carga

IP Hash

- Consistência de sessão baseada no IP
- Hash Consistentehash consistente a partir do endereço IP do cliente para determinar para qual host as requisições ou pacotes de rede serão direcionados.
- Empregada em componentes de rede (L4)
- Útil para manter a persistência da sessão em aplicações web.


IP Hash



IP Hash - Limitações

- Menos eficaz quando os usuários estão atrás de NATs ou proxies
- Muitos podem compartilhar o mesmo endereço IP de Borda (Público)
- Distribuição desigual de carga entre os servidores
- Base de usuários não estiver distribuída uniformemente em termos de endereços IP

IP Hash




Mangle

- Algoritmo desenvolvido pelo Google para alta escala
- Roteamento de Datacenter (Sessão)
- Usa tabelas de hash consistentes para mapear clientes e servidores
- Garante persistência e mínima flutuação no roteamento
- Excelente para balanceamento entre datacenters e multi-tenant
- Limitações em ambientes com escalabilidade horizontal rápida


Random

- Seleciona um host aleatoriamente do pool
- Zero dependência de estado ou métricas de carga
- Implementação extremamente simples e rápida
- Útil em cenários leves ou uniformes
- Limitações: pode gerar distribuição desigual e sobrecarga em hosts específicos



1


MODELO OSI (Em LB's)




**RECAP RAPIDO,
PROMETO...**

Modelo OSI

- Open Systems Interconnection (1980)
- Padronizar Sistemas de Telecomunicações
- Abstração Acadêmica
- Representação em Camadas
- Entendimento de Redes
- Entendimento de Protocolos
- Documentar onde Protocolos Operam
- Camadas mais altas são implementadas com Software






Load Balancers de Layer 4 (Transporte)


- Opera na camada de transporte do modelo OSI (TCP/UDP).
- Decide o roteamento baseado em endereços IP e portas.
- Baixa latência e alta performance, pois não interpreta payload da aplicação.
- Usado para distribuir tráfego de conexões (ex.: bancos de dados, VoIP, jogos online). Menos flexibilidade em regras de roteamento comparado a Layer 7.

Load Balancers de Layer 7 (Aplicação)

- Opera na camada de aplicação do modelo OSI (HTTP, gRPC, WebSocket).
- Permite roteamento avançado baseado em URLs, headers, querystrings.
- Suporta SSL/TLS offloading, cache e compressão.
- Ideal para APIs, microsserviços e aplicações web.
- Mais flexível que L4, mas com maior custo de processamento.




1. Implementações e Tecnologias



Principais
Tradeoffs

Envoy Proxy

- Cloud Native
- Proxy de Alta Performance
- Orientado a Escalabilidade
- Base de Service Mesh
- Base de Ingress Controllers
- Suporte Nativo a vários algoritmos
- Suporte a L4 e L7
- Load Balancer e Proxy Reverso
- Suporte a Control Plane e Dataplane




Nginx

- Leve, estável e com baixo consumo de recursos
- SSL/TLS offloading, cache e autenticação nativa
- Muito usado em produção pela simplicidade de configuração
- Suporte a L7
- Servidor web, proxy reverso e load balancer em um único binário



HAProxy

- Eficiência e Confiabilidade
- Algoritmos Avançados de Balanceamento
- SSL/TLS Offload
- Ambientes de Larga Escala



HAPROXY

Traefik

- Configuração dinâmica, integrado a Docker e Kubernetes
- Atualiza rotas automaticamente quando serviços sobem ou descem
- L4 e L7
- Simplicidade e Velocidade
- Balanceador de Carga




Ingress Controllers

- Kubernetes
- Gerenciam acesso externo
- Oferecem roteamento HTTP/HTTPS e TCP avançado
- simplificam acesso em ambientes multi-serviço
- SSL/TLS termination, regras de roteamento e observabilidade
- Nginx, HAProxy, Envoy, Traefik



Cloud Load Balancers

- Serviços gerenciados da AWS, GCP e Azure
- Escalabilidade elástica e integração nativa com a cloud
- Suporte a L4 (TCP/UDP) e L7 (HTTP/HTTPS)
- Recursos avançados: roteamento, SSL offloading, health checks
- Provisionamento via API



\$ whoami

Matheus Fidelis


Engenheiro de \$RANDOM

@fidelissauro

<https://fidelissauro.dev>

<https://linktr.ee/fidelissauro>





SlidesCarnival icons are editable shapes.

This means that you can:

- Resize them without losing quality.
- Change fill color and opacity.

Isn't that nice? :)

Examples:

