


System Design

Escalabilidade,
Performance e
Capacity



\$ whoami

Matheus Fidelis

Engenheiro de \$RANDOM

@fidelissauro

<https://fidelissauro.dev>


<https://linktr.ee/fidelissauro>



OBJETIVOS


- ✓ REFORÇAR TEORIA
- ✓ REPRESENTAR CONCEITUALMENTE
- ✗ FALAR SOBRE PROVIDERS
- ✗ DETALHAR TECNOLOGIAS DE FORMA NOMINAL
- ✗ DETALHAR FERRAMENTAL*

Detalhar os conceitos com a ótica de System Design, abstraindo suas implementações.




1

PERFORMANCE



Definições e
Conceitos







Isoladamente, ou em meio a
outras transações

**O quão rápido e eficiente um
sistema ou algoritmo pode ser ao
processar uma única transação.**

PERFORMANCE



- Eficiência ao cumprir um objetivo
- Metrificável
- Processar uma transação
 - Forma isolada
 - Grande volume
- Requisitos Funcionais e Não Funcionais
- Expectativas de Engenharia




MÉTRICAS DE PERFORMANCE

Performance é Metrificável

Métricas de Performance


- Desempenho de Sistemas variam sob Diferentes Condições


- Picos e Spikes de Carga
- Falhas de Componentes
- Mudanças de Padrão de Uso
- Mudanças de Design
- Mudanças de Business Cases
- Mudanças de Implementações



Métricas de Performance

- Observar de Forma Sequencial
- Insights e Oportunidades de Melhoria
- Períodos de Tempo
- Identificar Tendências
- Comparativos de Benchmarks
- Frameworks Starters
 - Service Levels
 - Four Golden Signals
 - RED
 - USE
 - ...






Four Golden Signals

Saturação, Tráfego, Tempo de Resposta e Taxa de Erros

Four Golden Signals

- Framework SRE
 - Saturação - O quanto de um recurso está em uso
 - Tráfego - O quanto de operações estão acontecendo
 - Tempo de Resposta - Tempo total das operações
 - Taxa de Erros - Quanto dessas operações estão falhando





Saturação

A Saturação de Recursos refere-se ao quanto do recurso disponível está sendo utilizado

Saturação - Utilização


- Utilização de Recursos
- *O quanto do disponível está em uso?*
- CPU, Memória, Disco, Pool de Conexões, Rate Limit, Rede
- Recurso saturado é um recurso com utilização se aproximando do máximo
- Prever e correlacionar problemas de desempenho

Saturação - Utilização

$$\text{Utilização de Recurso} = \left(\frac{\text{Recurso Utilizado}}{\text{Recurso Disponível}} \right) \times 100$$

$$\text{Utilização de Memória} = \left(\frac{1024}{2048} \right) \times 100$$

$$\text{Utilização de Memória} = 50\%$$



Tráfego - Throughput

Número de operações que um sistema consegue realizar dentro de um determinado período de tempo

Tráfego - Throughput


- Unidades de Trabalho por Unidade de Tempo
- Requisições, Transações, Mensagens, Eventos, Registros, Vendas e etc
- Segundo, Minuto, Hora, Dia, Semana, Mês...

Tráfego - Throughput

$$\text{Throughput} = \frac{\text{Unidades de Trabalho Processadas}}{\text{Tempo}}$$

$$\text{Throughput} = \frac{6000}{60}$$

$$\text{Throughput} = 100.00 \text{ rps}$$



Tempo de Resposta


O tempo total que leva desde o envio de uma solicitação
até o recebimento da resposta


Tempo de Resposta

- Ação até a Resposta
- Latência
- Processamento
- Tempo de Resposta

$\text{Tempo de Resposta} = \text{Timestamp da Resposta} - \text{Timestamp da Requisição}$

Tempo de Resposta





Taxa de Erro

Porcentagem de todas as requisições que resultam em um erro em relação ao total de requisições

Taxa de Erro

- Número de erros de um sistema
- Capacidade, Performance e Disponibilidade
- Confiabilidade Direta
- Menor Taxa e Maior Criticidade
- Observado em períodos de tempo

Taxa de Erro

$$\text{Taxa de Erro} = \left(\frac{\text{Número de Erros}}{\text{Número Total de Tentativas ou Eventos}} \right) \times 100$$


$$\text{Taxa de Erro} = \left(\frac{50}{1000} \right) \times 100$$

$$\text{Taxa de Erro} = 5.0\%$$

PERCENTIS


- Dividir uma amostra de dados ordenados em 100 partes iguais
- Usado para entender distribuição de dados
- P99, p90, p50, ...
- Gauges - Tempo de Resposta, Integrações...
- Vencer o "Problema da Média"

PERCENTIS



2


CAPACIDADE



Recipiente

Definições e
Conceitos

Encontrar o Limite Atual
do Sistema





**A quantidade máxima de trabalho que
o sistema pode receber e processar
de maneira eficaz em um determinado
período de tempo**

CAPACIDADE



- O quanto um sistema pode suportar
- Encontrar limites
- Recursos e Performance
- Encontrar Dimensionamento
- Planejar a Capacidade
- Carga atual, spikes e crescimento orgânico







Gargalo de Capacidade

Pontos no sistema onde o desempenho ou a capacidade são limitados

GARGALO

- O máximo que um componente do sistema pode suportar em relação ao todo
- Pontos de limitação de desempenho
- Componentes e processos específicos
- Oportunidades de otimização
- O Gargalo se move com o tempo







Backpressure de Capacidade


Uma resistência ao fluxo desejado

BACKPRESSURE DE CAPACIDADE



- Receber mais dados do que consegue processar
- Degradação de Sistemas Distribuídos
- Tempo de Resposta, Erros e Data Loss
- Capacidade Ociosa vs Super Utilizada
- *"Corrente é tão forte quanto seu elo mais fraco"* - Henry Ford





3

ESCALABILIDADE

Definições e
Conceitos

Um ar
condicionado







Escalabilidade

Capacidade de um sistema crescer e lidar com aumento de uso sem comprometer desempenho, qualidade e segurança.

ESCALABILIDADE

- Crescer e diminuir conforme demanda
- Sistemas que esperam aumento de volume
- Ambientes de Alta Demanda
- Ambientes de Demanda Variável
- Altamente metrificável






Escalabilidade Vertical

Aumentar ou reduzir a capacidade de um componente adicionando ou removendo recursos

ESCALABILIDADE VERTICAL

- Aumentar os recursos disponíveis
- CPU, Memória, Disco, Hardware Anyway
- Processamento de Tarefas
- Overhead
- Scale-UP - Escalar para cima
- Scale-Down - Escalar para baixo




Escalabilidade Horizontal

Adição ou remoção de unidades computacionais sob demanda

ESCALABILIDADE HORIZONTAL

- Adicionar ou remover replicas
- Pods, Tasks, Containers, Servidores, Nodes
- Elasticidade Sob Demanda
- Scale-Out - Adicionar
- Scale-In - Remover



MÉTRICAS DE ESCALA

Escalabilidade Contabilizada

FORMULA BÁSICA

- Encontrar a Capacidade Ideal para Escalar
- Baseado em uma variável metrificável
- HPA do Kubernetes*

$$\text{Réplicas Desejadas} = \text{Réplicas Atuais} \times \left(\frac{\text{Valor Atual da Variável}}{\text{Valor Desejado da Variável}} \right)$$

UTILIZAÇÃO DE RECURSOS

- Crescer e diminuir conforme demanda x

$$\text{Utilização de Recurso} = \left(\frac{\text{Recurso Solicitado}}{\text{Recurso Disponível}} \right) \times 100$$

Olha a
Saturação Aqui



$$\text{Réplicas Desejadas} = \text{Réplicas Atuais} \times \left(\frac{\text{Utilização de CPU}}{\text{Utilização Desejada de CPU}} \right)$$

UTILIZAÇÃO DE RECURSOS

- Réplicas Atuais: 6
- Recursos de Cada Replica: 200 milicores
- Recurso disponível: 600
- Recurso solicitado: 1200 milicores
- Utilização desejada de recurso: 80%

$$\text{Utilização de CPU} = \left(\frac{1200\text{m}}{600\text{m}} \right) \times 100$$

$$\text{Utilização de CPU} = 200\%$$

$$\text{Réplicas Desejadas} = 6 \times \left(\frac{200}{80} \right)$$

$$\text{Réplicas Desejadas} = 15$$

THROUGHPUT

- Réplicas Atuais: 6
- TPS de cada replica: 15 TPS
- Total de Requisições Recebidas: 10.000 por minuto

$$\text{Transações por Segundo} = \frac{\text{Total de Requisições Atendidas}}{\text{Período de Tempo}}$$

$$\text{Transações por Segundo} = \frac{10.000}{60}$$

$$\text{Transações por Segundo} = 166,66$$

$$\text{Requisições por Réplica} = \frac{\text{Transações por Segundo}}{\text{Réplicas Atuais}}$$

$$\text{Requisições por Réplica} = \frac{166,66}{6}$$

$$\text{Requisições por Réplica} = 27,78$$

Olha o tráfego aqui



$$\text{Réplicas Desejadas} = 6 \times \left(\frac{27,78}{15} \right)$$

$$\text{Réplicas Desejadas} = 11$$

\$ whoami

Matheus Fidelis


Engenheiro de \$RANDOM

@fidelissauro

<https://fidelissauro.dev>

<https://linktr.ee/fidelissauro>





SlidesCarnival icons are editable shapes.

This means that you can:

- Resize them without losing quality.
- Change fill color and opacity.

Isn't that nice? :)

Examples:

