

System Design



The diagram consists of a large rectangle with a solid border. Inside this rectangle, at the top, is the text 'System Design'. Below it, separated by a dashed horizontal line, is the text 'Capacity Planning'. A dashed curved arrow points from the right side of 'System Design' down to the right side of 'Capacity Planning'. Another dashed curved arrow points from the bottom left of the rectangle up towards the left side of 'Capacity Planning'.

Capacity Planning

\$ whoami

Matheus Fidelis

Engenheiro de \$RANDOM

@fidelissauro

<https://fidelissauro.dev>


<https://linktr.ee/fidelissauro>




OBJETIVOS

- ✓ Visão de Projeção
- ✓ Estimativas de Carga
- ✓ Previsão de Crescimento
- ✓ Teoria das Filas
- ✓ Dimensões Importantes


RECADOS






1

CAPACITY PLANNING




Objetivos e
Ganhos




Capacity Planning

- Capacity Planning não é previsão exata, é entendimento estrutural
- Incidentes surgem da incapacidade de interpretar carga real
- Métricas isoladas (CPU, TPS médio) não explicam comportamento sistêmico
- Concorrência interna e formação de filas como fenômenos centrais
- Quanto Aguenta vs Como se Comporta



2

Teoria das Filas




Objetivos e
Ganhos

Teoria das Filas

- Sistemas = demandas competindo por recursos finitos
- Fila como abstração universal (threads, conexões, locks, buffers)
- Cada microserviço como uma fila independente
- Latência e throughput como efeitos emergentes


Taxa de Chegada e Processamento

- λ define pressão externa
- μ define capacidade de vazão
- Gargalo surge quando $\lambda > \mu$
- Saturação precede uso máximo de recursos




Variedade como Fator Dominante

- Sistemas com mesma média, comportamentos distintos
- Desvio padrão e burstiness como vilões ocultos
- Autoscaling reage tarde a bursts
- Previsibilidade importa mais que capacidade bruta
- Coeficiente de Variação, Desvio Padrão ao invés de apenas percentís e médias




3

Lei de Little




Objetivos e
Ganhos



Lei de Little

- Concorrência Interna
- Relação entre L , λ e W
- Independente de distribuição estatística
- Aplicável a qualquer sistema estável
- Base para raciocínio de concorrência interna
- L : itens em processamento no sistema
- λ : Taxa média
- W : Tempo médio de processamento e permanência

$$L = \lambda \times W$$



Lei de Little

- L representa trabalho simultâneo no sistema
- Threads ocupadas, mensagens em voo, conexões abertas Base para dimensionamento preventivo
- Menor L = maior previsibilidade
- Pequenos aumentos em W → grandes aumentos em L
- Risco de crescimento não controlado filas

$$L = \lambda \times W$$

Exemplo: Processamento de Mensagens

- 1.500 mensagens por segundo
- 50ms de Tempo Médio de Processamento

$$L = \lambda \times W$$

$$L = 1.500 \times 0.05$$

$$L = 75$$

Exemplo: Processamento de Mensagens

- 1.500 mensagens por segundo
- 85ms de Tempo Médio de Processamento

$$L = \lambda \times W$$

$$L = 1.500 \times 0.085$$

$$L = 127$$

Lei de Little e o "Ponto Saudável"

- Encontrar um "Ponto Saudável" de operação
- Crescimento de Carga (λ)
- Aumento Controlado da Concorrência Interna (L)
- Definir um L(Alvo) como Service Level
- Operação previsível e com margem

"Ponto Saudável" e $L(\text{Alvo})$


- API REST com Padrões Estabelecidos
- Recebe 500 requisições por segundo
- tempo médio de resposta de 300ms

$$L = \lambda \times W$$

$$L = 500 \times 0.3$$

$$L = 150$$

Concorrência interna ($L = \lambda \times W$) e guardrail (L_{alvo})




Ajustando W para Crescimento Sustentável

- Encontrar o Ponto de Otimização
- API REST com Padrões Estabelecidos
- Recebe 500 requisições por segundo
- tempo médio de resposta de 300ms


$$W = \frac{L(\text{Alvo})}{\lambda} \times 1000$$

$$W = \frac{150}{1000} \times 1000$$

$$W = 150ms$$



4 Knee Curve: Onde o Sistema Quebra




Objetivos e
Ganhos

Knee Curve

- "Knee", Joelho
- Ou "Elbow", cotovelo
- Região linear vs região exponencial
- Onde o sistema não cresce de forma linear
- Latência cresce de forma não linear
- Filas dominam o tempo total
- Operar após o joelho é operar no risco

Latência (ms)


Requests por Segundo




Ponto Saudável e Ponto Máximo

- Zona ótima de eficiência
- Zona máxima de risco aceitável
- Diferença entre capacidade nominal e operacional
- Sistemas bem projetados não operam no máximo, operam com margem


Correlação de Requests e Latência



Correlação de Utilização e Vazão




Ponto Saudável e Ponto Máximo




Margens Seguras de Saturação


- Saturação não linear de CPU
- Filas crescem antes de 100%
- Zona segura geralmente entre 70–85%
- “CPU livre é desperdício”
- CPU livre é margem de absorção de variabilidade
- Absorver variações de carga, spikes, bursts e jitters
- sem exaurir a taxa de processamento (μ)

Margens Seguras de Saturação





5 Modelagem de Carga



Objetivos e
Ganhos

Modelagem de Carga: Dimensões

- Três Dimensões Principais
 - TPS: Chegada de Requisições/Mensagens
 - Concorrência: Pressão Interna
 - Payload: Conteúdo / Peso da Transação
- Nenhuma dessas dimensões isolada explica capacidade real.

Transações por Segundo

- Taxa de chegada (λ)
- Requisições / Mensagens / Processos
- Quantidade de interações que um sistema recebe
- Analisar Distribuição
- Dois sistemas podem operar com o mesmo TPS médio e apresentar comportamentos totalmente diferentes
- Bursts, Percentis, Spikes

Processos Concorrentes

- Taxa de Processamento (μ)
- Processos Concorrentes (L)
- Dimensão interna do sistema que reflete sua capacidade de processamento
- Latência aceitável com concorrência elevada
- Pré-condição para colapso

Payload e Cauda Longa

- Média de payload é enganosa
- Variabilidade cria caudas de latência
- Payloads maiores tendem a ampliar o tempo de processamento
- Impacto em GC, memória e rede
- Modelar sistemas e contratos que não sofram grande variação de tamanho

Estimativa de Transações por Segundo

- Comportamento do usuário à pressão exercida sobre a arquitetura
- valor estatístico médio, mínimo e máximo
- Não como um fluxo contínuo e uniforme
- Levantar o desvio padrão do TPS

$$\text{TPS} = \frac{\text{Unidades de Trabalho Processadas no Período}}{\text{Tempo em Segundos do Período}}$$

TPS Sistemico

- Arquiteturas distribuídas
- Gargalos de Microserviços
- Throughput observado externamente é sempre limitado pelo menor gargalo ativo no caminho de processamento

TPS Sistemico = $\min(\text{TPS App}, \text{TPS Database}, \text{TPS Cache}, \text{TPS etc.})$

Estimativa de Tamanho de Payload

- Quantificar o volume médio de dados trafegados por requisição
- Corpo da mensagem quanto o overhead de protocolos de transporte, como HTTP, TLS, mTLS, entre outros

$$\text{Payload_bytes} = (\text{Body_bytes} + \text{Headers_bytes})$$

$$\text{Payload_bytes} = (\text{Body_bytes} + \text{Headers_bytes}) \times \text{Overhead}$$

Estimativa de Transação


- Considera o custo completo de uma interação
- Requests e Response
- Análise de Capacidade Fim a Fim
- Custo e Banda sob Carga Real

$$\text{Payload_médio(bytes)} = \text{Request_payload} + \text{Response_payload}$$


Estimativa de Banda

- Throughput lógico (TPS) com o consumo físico de rede
- Estimar o volume de dados trafegados por segundo
- Dimensionar links, limites de ingress e custos de transferência.


$$\text{Banda_bytes/s} = \text{TPS} \times \text{Payload_médio(bytes)}$$



6 Perfils de Tráfego




Objetivos e
Ganhos




Perfil Diário

- Dimensão de um dia corrido (24 horas)
- Dias úteis ou não

Perfil Diário: Transações por Segundo




Perfil Diário: Tempo de Resposta




Perfil Semanal

- Dimensão de 7 dias corridos
- Padrões dentro da semana

Perfil Semanal: Transações por Segundo




Perfil Semanal: Tempo de Resposta




Perfil Sazonal


- Escalas mais longas
- Dimensões de Meses ou Anos
- Datas Comemorativas ou Períodos de Carga

Perfil Sazonal (12 meses): Transações por Segundo




Perfil Sazonal (12 meses): Tempo de Resposta






7 Projeção de Crescimento




Objetivos e
Ganhos



Crescimento Linear

- Crescimento proporcional e previsível ao longo do tempo
- Métricas como TPS, usuários ou volume de dados aumentam de forma relativamente constante
- Pequenas variações não descaracterizam o modelo linear
- Inferência comum: dobrar demanda $\approx$ dobrar capacidade
- Modelo válido quando variabilidade e perfil de tráfego permanecem estáveis


Crescimento Linear



Crescimento Não-Linear

- Crescimento irregular, exponencial ou por regimes alternados
- Pequenas variações externas geram aumentos desproporcionais em TPS, latência ou concorrência
- Invalida extrapolações baseadas apenas no histórico
- Extremamente perigoso quando o sistema já opera próximo da Curva do Joelho
- Comum em produtos em expansão, mudanças de comportamento ou novos canais


Crescimento Não-Linear




Novas Features e Eventos De Negócio

- Crescimento induzido por ações planejadas: features, campanhas, migrações, eventos
- Mudanças alteram o perfil de tráfego, não apenas o volume
- Uma feature raramente “só aumenta TPS”; ela muda a topologia do sistema
- Planejamento de Marketing
- Eventos Estratégicos Planejados
- Alinhamento entre engenharia e negócio para antecipar impactos

Novas Features e Eventos De Negócio





8 Capacidade End to End (E2E)

Objetivos e
Ganhos


Capacidade End to End

- Responsabilidade pelo fluxo completo
- Variabilidade acumulado
- Capacidade emerge da composição
- Throughput individual
- Throughput sistêmico

Throughput Individual

- Capacidade máxima sustentável de um componente isolado dentro do sistema
- Descreve quanto trabalho um serviço, banco de dados, fila ou consumidor consegue processar por unidade de tempo sob condições controladas
- Contexto de um microserviço e suas dependências diretas


Throughput Individual



Throughput Sistemico

- Capacidade máxima de um sistema ou funcionalidade, contemplando todas as suas dependências
- Todos os Serviços Envolvidos
- Ser agnóstico à capacidade individual de cada componente
- Avaliar a capacidade total da solução
- Identificar oportunidades de melhoria relacionadas a filas e gargalos


Throughput Sistemico




Dependência do Gargalo

- Pontos no sistema onde o desempenho ou a capacidade são limitados devido a um componente específico
- O gargalo atual do sistema é representado pelo componente ou processo com a menor taxa de processamento (μ)
- Direcionar melhorias de forma priorizada e estratégica

Dependência do Gargalo




$$\text{Gargalo} = \min(s_1, s_2, s_3, \dots)$$



9 Planejamento de Capacidade



Objetivos e
Ganhos



Planejamento de Capacidade

- Levantar as Estimativas de Carga
- Identificação do Throughput Individual
- Derivação do Throughput Sistêmico
- Levantamento da Projeção de Crescimento
- Avaliar o Custo e as Margens Operacionais
- Definição dos Limites Operacionais
- Testes de Carga e Estresse

\$ whoami

Matheus Fidelis


Engenheiro de \$RANDOM

@fidelissauro

<https://fidelissauro.dev>

<https://linktr.ee/fidelissauro>





SlidesCarnival icons are editable shapes.

This means that you can:

- Resize them without losing quality.
- Change fill color and opacity.

Isn't that nice? :)

Examples:

